

6.1.2 Gauss - Markov 定理:

特定条件下 LS 最优. 使得 LS 变得伟大

* 最优无偏解 (统计信号处理)

须满足的条件:

$$\underline{A}\underline{x} = \underline{b} + \underline{e} \rightarrow \text{随机误差向量}$$

$$\left\{ \begin{array}{l} \text{误差均值为0} \quad E\{\underline{e}\} = 0 \\ \text{协方差} \quad \text{cov}\{\underline{e}\} = E\{\underline{e}\underline{e}^H\} = \sigma^2 \underline{I} \end{array} \right.$$

在参数估计理论中, 称参数向量 θ 的估计 $\hat{\theta}$ 为无偏估计, 若 $E(\hat{\theta}) = \theta$. (真实 θ 未知, 参数向量). 如果一个无偏估计还具有方差最小, 称这一无偏估计为最优无偏估计.

高斯白噪声

↓
最优无偏解由最小二乘解给出

* 最大似然解 6.1.3
(概率)

3. LS 解与最大似然解的等价性 (3解)

LS 初步泛应用

复高斯随机向量 (加性误差向量 $\underline{e} = [e_1, e_2, \dots, e_m]^T$ 为独立同分布)

$$f(\underline{e}) = \frac{1}{\pi^m |\underline{e}|} \exp[-(\underline{e} - \underline{u}_e)^H \underline{I}_e^{-1} (\underline{e} - \underline{u}_e)]$$

概率密度函数

↓
协方差矩阵:

误差向量下各分量均
具有零均值和
相同方差 σ^2 .

$$[\underline{I}_e = \sigma^2 \underline{I}]$$

$$= \frac{1}{(\pi \sigma^2)^m} \exp\left[-\frac{1}{\sigma^2} \underline{e}^H \underline{e}\right]$$

$$\|\underline{A}\underline{x} - \underline{b}\|^2$$

$$\text{估计 } \underline{x} \text{ 使得 } f(\underline{e}) \text{ 最大} \Leftrightarrow \min \|\underline{A}\underline{x} - \underline{b}\|^2$$

4. 数据最小二乘

$$\underline{A} = \underline{A}_0 + \underline{E}$$

\underline{A} :

数据矩阵: 观测误差或噪声.

对 \underline{A} 校准

$$(\underline{A} + \Delta \underline{A}) \underline{x} = \underline{b}$$

当误差向量 \underline{e} 为零均值的高斯随机向量, 但其元素具有不同方差时, 这种情况下的最大似然解将不可能等于最小二乘解. 因此, 最小二乘解不一定是最优的.

$$\min_{\underline{A}} \|\Delta \underline{A}\|_F^2, \quad \text{s.t.} \quad (\underline{A} + \Delta \underline{A}) \underline{x} = \underline{b}$$

↓ F范数

$\min L(\underline{x})$

$$= \text{tr}(\Delta \underline{A}(\Delta \underline{A})^H) + \lambda^H (\underline{A} \underline{x} + \Delta \underline{A} \underline{x} - \underline{b})$$

↑ 拉格朗日乘子法

$\min [\quad]$ 无约束优化问题

$$\frac{\partial L(\underline{x})}{\partial \Delta \underline{A}} = 0 \Rightarrow \begin{aligned} \Delta \underline{A} &= -\underline{\lambda} \underline{x}^H \\ (\Delta \underline{A})^H + \underline{x} \underline{\lambda}^H &= 0 \end{aligned} \quad \Delta \underline{A} = -\underline{\lambda} \underline{x}^H$$

↓
应该是对 $\Delta \underline{A}^T$ 求导

$$\frac{\partial L(\underline{x})}{\partial \Delta \underline{A}} = \Delta \underline{A} + \underline{\lambda} \underline{x}^H = 0$$





$$\underline{A}\underline{x} = \underline{b}$$

与普通最小二乘不同. 这里假定数据向量 \underline{b} 无观测误差或噪声. 只有数据矩阵 $\underline{A} = \underline{A}_0 + \underline{E}$ 有观测误差或噪声. 且误差矩阵 \underline{E} 的每个元素符合零均值. 等方差的独立高斯分布.

* 考虑用校正矩阵 $\Delta \underline{A}$ 干扰有误差的数据矩阵 \underline{A} . 使得

$$\underline{A} + \Delta \underline{A} = \underline{A}_0 + \underline{E} + \Delta \underline{A} \rightarrow \underline{A}_0$$

* 将 $\Delta \underline{A} = -\lambda \underline{x} \underline{x}^H$ 代入约束条件 $(\underline{A} + \Delta \underline{A})\underline{x} = \underline{b}$. 即有 $\lambda = \frac{\underline{A}\underline{x} - \underline{b}}{\underline{x}^H \underline{x}}$

从而有 $\Delta \underline{A} = -\frac{(\underline{A}\underline{x} - \underline{b})\underline{x}^H}{\underline{x}^H \underline{x}}$. 原目标函数

$$J(\underline{x}) = \|\Delta \underline{A}\|_F^2 = \text{tr}[\Delta \underline{A}(\Delta \underline{A})^H] = \text{tr}\left(\frac{(\underline{A}\underline{x} - \underline{b})\underline{x}^H}{\underline{x}^H \underline{x}} \frac{\underline{x}(\underline{A}\underline{x} - \underline{b})^H}{\underline{x}^H \underline{x}}\right)$$

$$\text{tr}(\underline{B}\underline{C}) = \text{tr}(\underline{C}\underline{B})$$

$$J(\underline{x}) = \frac{(\underline{A}\underline{x} - \underline{b})^H (\underline{A}\underline{x} - \underline{b})}{\underline{x}^H \underline{x}}$$

$$\text{由此得: } \hat{\underline{x}}_{\text{OLS}} = \underset{\underline{x}}{\text{argmin}} \frac{(\underline{A}\underline{x} - \underline{b})^H (\underline{A}\underline{x} - \underline{b})}{\underline{x}^H \underline{x}}$$