



第五讲.

$$\underline{L}[\underline{u}] = \lambda \underline{u}, \quad \underline{u} \neq 0$$

- *. 只有当特征向量 \underline{u} 作线性系统 L 的输入时, 系统的输出才具有与输入相同这一重要特征.



特征向量可以看作是表征系统特征的向量.

*. $\underline{A}\underline{u} = \lambda \underline{u}$

\underline{A} : Hermitian 矩阵 $\underline{A} = \underline{U} \underline{\Lambda} \underline{U}^H$. 特征值为实数.

$$(\underline{A} - \lambda \underline{I}) \underline{u} = 0$$

存在非零解 $\underline{u} \neq 0$ 的唯一条件是 $\det(\underline{A} - \lambda \underline{I}) = 0$

- *. 同一特征值重复的次数称为特征值的重数.

- *. 若特征值具有非零解 $\underline{x} \neq 0$, 则标量 λ 必然使 $n \times n$ 矩阵 $\underline{A} - \lambda \underline{I}$ 奇异

(1). 求出所有使矩阵 $\underline{A} - \lambda \underline{I}$ 奇异的标量 λ : 特征值

(2). 对每个 λ , 求出所有满足 $(\underline{A} - \lambda \underline{I})\underline{x} = 0$ 的非零向量 \underline{x} , 与 λ 对应的特征向量.



*. 定义:

令 \underline{A} 是一个 $n \times n$ 矩阵. 则 n 阶多项式

$$P(x) = \det(\underline{A} - x\underline{I}) = \begin{vmatrix} a_{11}-x & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22}-x & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn}-x \end{vmatrix}$$

$$= p_n x^n + p_{n-1} x^{n-1} + \cdots + p_1 x + p_0$$

称为矩阵 \underline{A} 的特征多项式:

$$P(x) = \det(\underline{A} - x\underline{I}) = 0$$

称为矩阵 \underline{A} 的特征方程.

特征方程的根称为矩阵 \underline{A} 的特征值.

*. $\text{tr}(\underline{A}) = \sum_{i=1}^n \lambda_i$

矩阵特征值与

矩阵的行列式

和迹的关系

$$\det(\underline{A}) = \prod_{i=1}^n \lambda_i$$

令 $\underline{s}(t) = [s_1(t), s_2(t), \dots, s_n(t)]^T$ 表示 n 个信号组成的向量.

且 $\underline{R}_s = E[\underline{s}(t) \underline{s}^H(t)]$ 表示信号 $\underline{s}(t)$ 的相干矩阵.

对角线元素之和:

\Rightarrow 几个信号功率之和

特征值之和



浙江大学

ZHEJIANG UNIVERSITY

考虑矩阵 A 的 n 次多项式.

$$f(A) = A^n + C_1 A^{n-1} + \dots + C_{n-1} A + C_n I$$

$$A \underline{u} = \lambda \underline{u} \quad A^2 \underline{u} = \lambda A \underline{u} = \lambda^2 \underline{u} \quad \dots \quad A^n \underline{u} = \lambda^n \underline{u}$$

$$(A^n + C_1 A^{n-1} + \dots + C_n I) \underline{u}$$

$$= (\lambda^n + C_1 \lambda^{n-1} + \dots + C_n) \underline{u}$$

$$\text{即: } f(A) \underline{u} = f(\lambda) \underline{u}$$

$f(\lambda)$ 为矩阵多项式 $f(A)$ 的特征值.

$$f(\lambda) = \lambda^n + C_1 \lambda^{n-1} + \dots + C_n$$

矩阵论. 2000.9.29

第7章 特征分析


7.2.2 特征向量

7.2.3

矩阵的谱: 所有特征值的集合, $\lambda_1, \lambda_2, \dots, \lambda_n$

谱半径: $\rho(A) = \max(|\lambda_i|)$ 特征值中绝对值最大的值

(非实数)



矩阵多项式:

$$f(\underline{A}) = \underline{A}^n + C_1 \underline{A}^{n-1} + \dots + C_{n-1} \underline{A} + C_n \underline{I}$$

$$f(\lambda) = \lambda^n + C_1 \lambda^{n-1} + \dots + C_{n-1} \lambda + C_n$$

$$e^{\underline{A}} \sim e^{\lambda}$$

$$e^{\underline{A}} = \underline{I} + \underline{A} + \frac{1}{2!} \underline{A}^2 + \dots = \sum_{i=0}^{\infty} \frac{1}{i!} \underline{A}^i$$

$$f(\lambda) = \sum_{i=0}^{\infty} \frac{1}{i!} \lambda^i = e^{\lambda}$$

7.2.4 7.2.5 仅需了解

7.3. Cayley Hamilton 定理及其应用

特征多项式 $P(\lambda) = \det(\underline{A} - \lambda \underline{I})$

$= p_n \lambda^n + p_{n-1} \lambda^{n-1} + \dots + p_1 \lambda + p_0$ 是使矩阵 \underline{A} 零化的多项式

$$P(\underline{A}) = p_n \underline{A}^n + p_{n-1} \underline{A}^{n-1} + \dots + p_1 \underline{A} + p_0 \underline{I} = \underline{0}$$

\underline{A}^{-1} 中用的比较多

\underline{A}^n 用的比较少 (随着计算机发展)

方程两边同时乘以 A^{-1}

$$P_n \underline{A}^{n-1} + P_{n-1} \underline{A}^{n-2} + \dots + P_1 \underline{I} + P_0 \underline{A}^{-1} = 0$$

$$\underline{A}^{-1} = -\frac{1}{P_0} (P_n \underline{A}^{n-1} + P_{n-1} \underline{A}^{n-2} + \dots + P_1 \underline{I}) \quad \text{正指数计算}$$

未知量: 系数. (特征多项式求) 例 1.3.2 P417

7.7.3 $A^{(3)}$

先解方程组. 求系数.

7.4 特征分解的典型应用 (信号处理用很多)

7.4.1 标准正交变换

\underline{x} 随机向量 $m \times 1$ 维. 均值 \underline{m}_x . 协方差矩阵 \underline{C}_x .
相关矩阵 \underline{R}_x

$$\underline{x}_0 = \underline{x} - \underline{m}_x \quad \text{去掉直流信号}$$

$$\underline{R}_{x_0} = \underline{C}_x \quad (\text{复共轭对称})$$

$$\underline{C}_x = \underline{U}_x \underline{\Sigma}_x \underline{U}_x^H \quad \text{特征分解}$$

$$\underline{W} = \underline{U}_x^H \underline{x}_0 = \underline{U}_x^H (\underline{x} - \underline{m}_x) \quad \text{线性变换}$$

$$\underline{m}_w = 0 \quad (\text{均值为0}) \quad \text{因此: } \underline{C}_w = \underline{R}_w = E\{\underline{W} \underline{W}^H\}$$

$$= \underline{U}_x^H \underline{R}_{x_0} \underline{U}_x$$

$$= \underline{U}_x^H \underline{C}_x \underline{U}_x$$

$$= \underline{U}_x^H \underline{U}_x \underline{\Sigma}_x \underline{U}_x^H \underline{U}_x$$

$$= \underline{\Sigma}_x$$

有色噪声白化.

变成对称阵


非对称 \rightarrow 对称

例: 匹配滤波. 常见: 高斯白噪声

实际: 均为有色, 先做白化. 再做匹配滤波及处理

逆同圆变换 (等对称化)

二维情况:



标准正交变换: 线性变换 $\underline{U}^H \underline{x}_0$ 的对称矩阵为对称矩阵, 但不是单位矩阵.

各向同性分布或者逆同分布

$$\underline{y} = \sum \underline{x}^{-1/2} \underline{W} \quad \underline{R}_y = E\{\underline{y} \underline{y}^H\} = \underline{I}$$

$$= (\sum \underline{x})^{1/2} \underline{U}_x^H (\underline{x} - \underline{m}_x)$$

得到单位阵有什么好处? m 个独立随机过程分解 同化为具有单位方差白噪声

对 \underline{x} 作自适应滤波. 收敛速度比较快


7.4.3 离散 K-L 变换

随机信号: $\underline{x} = [x_1, x_2, \dots, x_m]^T$
 零均值, 随机向量
 $\left\{ \begin{array}{l} \text{维数大} \\ \text{元素间相关} \end{array} \right.$

用小维度的 \underline{W} 表示 \underline{x}

线性变换: $\underline{W} = \underline{Q}^H \underline{x}$
 $N \times 1$
 \underline{Q} : 对称矩阵 \downarrow 相关矩阵 \downarrow 特征向量
 $\underline{R}_x = \underline{Q} \underline{\Sigma} \underline{Q}^H$
 \downarrow 特征值

原随机信号 \underline{x} 也可以用线性正交变换矩阵 \underline{Q} 表示
 或 \underline{W} 的线性组合
 为 \underline{Q} 的变换后 \underline{W} 的系数
 只使用 \underline{W} 的前 m 个系数
 $\underline{W}_1, \dots, \underline{W}_m$ 逼近随机信号 \underline{x}
 $\underline{x} \approx \sum_{i=1}^m \underline{q}_i \underline{W}_i$



$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m \geq \dots \geq \lambda_m$$

误差: $\underline{e} = \underline{x} - \hat{\underline{x}} = \sum_{i=1}^m \underline{q}_i \underline{W}_i - \sum_{i=1}^m \underline{q}_i \underline{W}_i = \sum_{i=m+1}^m \underline{W}_i \underline{q}_i$

7.4.4. 主成份(分量)分析

信号处理中常用到 x_1, x_2, \dots, x_p : 每个指标是唯一的, 正交的
 冗余: 统计相关 \rightarrow 信息冗余

互相耦合: 解耦

分类识别算法: 几千个指标 \rightarrow 提取出彼此正交的 k 个新变量

方式: $\underline{\tilde{x}} = \underline{Q}^H \underline{x}$ 正交变换: 新特征相互正交

$$= \sum_{i=1}^p q_i x_i$$

$$\approx \sum_{i=1}^k q_i x_i$$

$$k < p$$

具有较大功率的 k 个性质指标
 可以视为对原始性质指标的近似
 成分

7.5 λ 特征分解: 了解概念

$$\underline{A} \underline{u} = \lambda \underline{u}$$

$$\lambda x: \underline{A} \underline{u} = \lambda \underline{B} \underline{u}$$

$$\det(\underline{A} - \lambda \underline{B})$$

7.6.1 Rayleigh 商及其性质

目标函数: $R(\underline{x}) = \frac{\underline{x}^H \underline{A} \underline{x}}{\underline{x}^H \underline{x}} \rightarrow \max$
 $\rightarrow \min$ \underline{A} : Hermitian 矩阵
 \underline{x} : 待选择向量

假设信号 $\underline{r}(t) = \underline{B} \underline{\alpha}(t) + \underline{n}(t)$
 信号经信道衰减

滤波器 \underline{x}^H 对 \underline{r} 滤波输出 SNR 最大

$$\frac{|\underline{x}^H \underline{B} \underline{\alpha}(t)|^2}{|\underline{x}^H \underline{n}|^2} = \frac{|\underline{x}^H \underline{B} \underline{\alpha}(t)|^2}{\underline{x}^H \underline{n} \underline{n}^H \underline{x}} = \frac{\underline{x}^H \underline{A} \underline{x}}{\sigma^2 \underline{x}^H \underline{x}} = \text{SNR}(\underline{x})$$

向噪声 σ^2

对 \underline{A} 作特征值分解:

Rayleigh-Ritz 定理:

$$\max_{\underline{x} \neq 0} \frac{\underline{x}^H \underline{A} \underline{x}}{\underline{x}^H \underline{x}} = \max_{\underline{x}^H \underline{x} = 1} \frac{\underline{x}^H \underline{A} \underline{x}}{\underline{x}^H \underline{x}} = \lambda_{\max} \quad \frac{\underline{x}^H \underline{A} \underline{x}}{\underline{x}^H \underline{x}} = \lambda_{\max}$$

$$\min_{\underline{x} \neq 0} \frac{\underline{x}^H \underline{A} \underline{x}}{\underline{x}^H \underline{x}} = \min_{\underline{x}^H \underline{x} = 1} \frac{\underline{x}^H \underline{A} \underline{x}}{\underline{x}^H \underline{x}} = \lambda_{\min} \quad \frac{\underline{x}^H \underline{A} \underline{x}}{\underline{x}^H \underline{x}} = \lambda_{\min}$$

$$\underline{x} = \underline{q}_{\max} = \frac{\lambda_{\max}}{1}$$

$$\underline{x} = \underline{q}_{\min} = \lambda_{\min}$$

信号不确定性: $\underline{x} = S(t)$

随机: 相关矩阵的最大特征值对应的特征向量

厄米矩阵

7.7.1 广义 Rayleigh 商

$$R(\underline{x}) = \frac{\underline{x}^H \underline{A} \underline{x}}{\underline{x}^H \underline{B} \underline{x}}$$

\underline{B} : 正定

\underline{B} : 噪声的相关矩阵. Hermitian 矩阵

先对分母作变量代换:

$$\underline{\tilde{x}} = \underline{B}^{1/2} \underline{x}$$

$$(\underline{B}^{1/2})^H = \underline{B}^{1/2} \quad \text{Hermitian 矩阵}$$

$$R(\underline{x}) = \frac{\underline{\tilde{x}}^H (\underline{B}^{1/2})^H \underline{A} \underline{B}^{1/2} \underline{\tilde{x}}}{\underline{\tilde{x}}^H \underline{\tilde{x}}}$$

特征值开根号. 特征向量不变

$$(\underline{B}^{1/2})^H \underline{A} \underline{B}^{1/2} \underline{\tilde{x}} = \lambda \underline{\tilde{x}} \quad \begin{cases} \min \\ \max \end{cases}$$

最后求 \underline{x} 特征值问题 $\underline{A} \underline{x} = \lambda \underline{B} \underline{x}$

左乘 $\underline{B}^{-1/2}$,

$$\underline{B}^{-1/2} \underline{B}^{1/2} \underline{\tilde{x}} = \lambda \underline{\tilde{x}}$$

$$\underline{B}^{-1} \underline{A} \underline{x} = \lambda \underline{x}$$