

上次: 奇异值分解 (第五章)

5.2.2 酉不变性 (奇异值)

$$A = U \Sigma V^H$$

$$B = P A Q^H = \underbrace{P U}_{\text{酉矩阵}} \Sigma \underbrace{(Q V)^H}_{\text{酉矩阵}}$$

酉矩阵

奇异值不变: 酉不变性
奇异向量不同

5.2.3 秩亏缺 LS (不是满秩) 应用奇异值分解求解最小二乘问题

$$A x = b$$

第一种方法:

$$U \Sigma V^H x = b$$

$$\Sigma V^H x = U^H b \quad \text{令 } \begin{cases} x' = V^H x \\ y = U^H b \end{cases}$$

$$\| \Sigma x' - U^H b \|_2^2 \rightarrow \min$$

$$\sum_{i=1}^r |\sigma_i x_i' - y_i|^2 + \sum_{i=r+1}^N |y_i|^2$$

求出 $x_i' \rightarrow x'$

矩阵近似:

B 矩阵近似 A .

如何衡量是否近似.

第二种方法:

$$A x = b \Rightarrow U \Sigma V^H x = b$$

$$x = \underline{A} b = (U \Sigma V^H)^+ b = V \Sigma^+ U^H b$$

$$\Sigma^+ = \text{diag}(1/\sigma_1, 1/\sigma_2, \dots, 1/\sigma_r, 0, \dots, 0)$$

$$x = \sum_{i=1}^r \left(\frac{u_i^H b}{\sigma_i} \right) v_i$$

最小二乘问题的最佳解

相应的最小残差为:

$$\| r_{LS} \| = \| [u_{r+1}, u_{r+2}, \dots, u_n]^H b \|_2$$

$$A = \sum_{i=1}^r \sigma_i u_i v_i^H$$

$\text{rank}(B) = K$. 先确定 B 的秩



定理: $\underline{A} \in \mathbb{R}^{m \times n}$ 的奇异值分解由 $\underline{A} = \sum_{i=1}^P \sigma_i \underline{u}_i \underline{v}_i^H$ 给出, 其中
 $P = \text{rank}(\underline{A})$. 若 $k < P$ 且 $\underline{B} = \sum_{i=1}^k \sigma_i \underline{u}_i \underline{v}_i^H$. 则通近质
量分别使用谱范数和 Frobenius 范数衡量

$$\min_{\text{rank}(\underline{B})=k} \|\underline{A} - \underline{B}\|_{\text{spec}} = \sigma_{k+1}.$$

$$\min_{\text{rank}(\underline{B})=k} \|\underline{A} - \underline{B}\|_F = \sqrt{\sum_{i=k+1}^P \sigma_i^2} \quad q = \min\{m, n\}$$

理论上 $i > r$ 时, $\sigma_i = 0$.

实际上 $\sigma_i \neq 0$. 有时甚至出现比较大的扰动

估计有必根个.

求解有两种方法:

奇异值分解 $\frac{\sigma_k}{\sigma_1}$ 归化奇异值方法 最大奇异值 $\varepsilon \geq 5\%$ 判断在哪里截断

$$B = \sum_k \sum_k V_k^H$$

范数化方法: \rightarrow 令 $m \times n$ 矩阵 A_k 是原 $m \times n$ 矩阵 A 的秩 k 近似

$$\rho(k) = \frac{\|A_k\|_F}{\|A\|_F} = \frac{\sqrt{\sigma_1^2 + \sigma_2^2 + \dots + \sigma_k^2}}{\sqrt{\sigma_1^2 + \dots + \sigma_r^2}} \geq \alpha \text{ 门限}$$

选择满足 $\rho(k) \geq \alpha$ 的最小整数作为有效秩估计。
 α 是接近于 1 的数值. $\alpha = 0.997$

图像. 视频压缩.

$$A: n \times n$$

$$A_k = \sum_{k=1}^k V_k \quad nk + k + kn = (2n+1)k$$

$$nk \quad k \quad kn$$

$$\text{压缩: } k < \frac{n^2}{2n+1}$$

通常: A 矩阵稀疏.

5.15: 判断有效秩的门限: (习题)

5.9 5.10

5.14 5.15

$$\text{rank} = \max_i \frac{\sigma_i}{\sigma_1} = \varepsilon$$

$$\varepsilon = 5\% \quad 3\%$$

第六章 (工程应用书) 矩阵方程求解

6.1 最小二乘方法:

1. 普通最小二乘方法:

超定方程: $\underset{m \times n}{A} \underset{n \times 1}{x} = \underset{m \times 1}{b}$ $m > n$

$$\underline{b} + \Delta \underline{b} = \underline{b}_0 + \underline{e} + \Delta \underline{b} \rightarrow \underline{b}_0$$

$$\underline{b} = \underline{b}_0 + \underline{e} \Rightarrow \text{加上的观测误差或噪声.}$$

$$\underline{A} \underline{x} = \underline{b} + \Delta \underline{b} \Rightarrow \text{校正向量}$$

$$\|\Delta \underline{b}\|_2^2 \rightarrow \min:$$

$$\min_{\underline{x}} \|\underline{A} \underline{x} - \underline{b}\|_2^2$$

↓
LS

可以理解为 $\min_{\underline{x}} \|\Delta \underline{b}\|_2^2$ 条件优化问题
s.t. $\underline{A} \underline{x} = \underline{b} + \Delta \underline{b}$

最小二乘的核心思想: 求出方程解向量 \underline{x}
能够使得方程两边的误差平方和最小

不同应用领域: 不同解释

$$\begin{aligned} \text{目标函数: } \phi(\underline{x}) &= (\underline{A} \underline{x} - \underline{b})^H (\underline{A} \underline{x} - \underline{b}) \\ &= \underline{x}^H \underline{A}^H \underline{A} \underline{x} - \underline{x}^H \underline{A}^H \underline{b} - \underline{b}^H \underline{A} \underline{x} + \underline{b}^H \underline{b} \end{aligned}$$

$$\text{一阶导} = 0 \quad \text{二阶导} > 0$$

这里可以不讲

$$\underline{A}^H \underline{A} \text{ 必预正定} \quad \underline{A}^H \underline{A} \succcurlyeq 0$$

$$\text{信号处理: 相关矩阵 (或者估计)} \quad \hat{\underline{R}}_x > 0$$

$$\hat{\underline{R}}_x + \delta \underline{I} > 0$$

正则化

δ 取值: 一定对角矩阵

默认 $\underline{A}^H \underline{A}$ 正定.

$$\frac{\partial \phi}{\partial \underline{x}} = (\underline{x}^H \underline{A}^H \underline{A})^T - (\underline{b}^H \underline{A})^T = 0$$

$$\frac{\partial \phi}{\partial \underline{x}} = \underline{A}^H \underline{A} \underline{x} - \underline{A}^H \underline{b} = 0$$

$$\underline{x} = (\underline{A}^H \underline{A})^{-1} \underline{A}^H \underline{b} \quad \text{视缺: SVD. 伪逆} \rightarrow \underline{x}_{LS} = (\underline{A}^H \underline{A})^+ \underline{A}^H \underline{b}$$

6.1.2 Gauss - Markov 定理:

特定条件下 LS 最优. 使得 LS 变得伟大

* 最优无偏解 (统计信号处理)

须满足的条件:

$$\underline{A}\underline{x} = \underline{b} + \underline{e} \rightarrow \text{随机误差向量}$$

$$\left\{ \begin{array}{l} \text{误差均值为0} \quad E\{\underline{e}\} = 0 \\ \text{协方差} \quad \text{cov}\{\underline{e}\} = E\{\underline{e}\underline{e}^H\} = \sigma^2 \underline{I} \end{array} \right.$$

在参数估计理论中, 称参数向量 θ 的估计 $\hat{\theta}$ 为无偏估计, 若 $E(\hat{\theta}) = \theta$. (真实 θ 未知, 参数向量). 如果一个无偏估计还具有方差最小, 称这一无偏估计为最优无偏估计.

高斯白噪声

↓
最优无偏解由最小二乘解给出

* 最大似然解 6.1.3
(概率)

3. LS 解与最大似然解的等价性 (3解)

LS 初步泛应用

复高斯随机向量 (加性误差向量 $\underline{e} = [e_1, e_2, \dots, e_m]^T$ 为独立同分布)

$$f(\underline{e}) = \frac{1}{\pi^m |\underline{e}|} \exp[-(\underline{e} - \underline{u}_e)^H \underline{I}_e^{-1} (\underline{e} - \underline{u}_e)]$$

概率密度函数

↓
协方差矩阵:

误差向量下各分量间
具有零均值和
相同方差 σ^2 .

$$[\underline{I}_e = \sigma^2 \underline{I}]$$

$$= \frac{1}{(\pi \sigma^2)^m} \exp\left[-\frac{1}{\sigma^2} \underline{e}^H \underline{e}\right]$$

$$\|\underline{A}\underline{x} - \underline{b}\|^2$$

$$\text{估计 } \underline{x} \text{ 使得 } f(\underline{e}) \text{ 最大} \Leftrightarrow \min \|\underline{A}\underline{x} - \underline{b}\|^2$$

4. 数据最小二乘

$$\underline{A} = \underline{A}_0 + \underline{E}$$

\underline{A} :

数据矩阵: 观测误差或噪声.

对 \underline{A} 校准

$$(\underline{A} + \Delta \underline{A}) \underline{x} = \underline{b}$$

当误差向量 \underline{e} 为零均值的高斯随机向量, 但其元素具有不同方差时, 这种情况下的最大似然解将不可能等于最小二乘解. 因此, 最小二乘解不一定是最优的.